

SWE-bench-official-pylint10_20260817

SWE-bench Verified 官方 Harness 评测报告（pylint 10 实例）

日期: 2026-08-17 | 评测: swebench 4.1.0 官方 harness + Docker（OrbStack）+ Rosetta 2
数据: SWE-bench Verified (princeton-nlp/SWE-bench_Verified) pylint-dev/pylint 全 10 实例
结果: 10/10 resolved（100%）
resolved 定义（严格遵循官方）: F2P 全部通过 $\wedge$ P2P 全部通过，二者缺一不可

环境与方法

- 运行时: OrbStack（macOS 26.5.1 arm64, 18 核/128GB）+ Docker 29.4.0（OrbStack 内置 CLI）+ swebench 4.1.0（Python 3.14 venv）
- 镜像: 官方远端镜像 swebench/sweb.eval.{arm64,x86_64}.*
 - arm64 直接拉取（原生架构）
 - x86_64 实例（4604/6386/7080）需 `docker pull --platform linux/amd64` 预拉 + Rosetta 模拟运行
- predictions: 每实例 model_patch = git diff（仅 src/setup.cfg，不含测试文件改动）
- 判定: 官方 harness F2P 全过 AND P2P 全过 = resolved

结果

#	实例	架构	F2P	结果	备注
1	pylint-4551	arm64	10/10	✅ resolved	
2	pylint-4604	x86_64	21/21	✅ resolved	
3	pylint-4661	arm64	1/1	✅ resolved	初跑失败→补 appdirs 依赖后过
4	pylint-4970	arm64	1/1	✅ resolved	
5	pylint-6386	x86_64	1/1	✅ resolved	
6	pylint-6528	arm64	4/4	✅ resolved	初跑 P2P 3 失败→补

					basename 定义 后重跑通过
7	pylint-6903	arm64	1/1	✓ resolved	
8	pylint-7080	x86_64	1/1	✓ resolved	
9	pylint-7277	arm64	1/1	✓ resolved	
10	pylint-8898	arm64	1/1	✓ resolved	

官方评测 vs venv 定性评测的差异（重要发现）

官方 harness 暴露了 2 个 venv 漏检的问题：

- 1. **pylint-4661（XDG 目录规范）**：venv 全过，官方 F2P 失败
 - 根因: 官方 test_patch 引入 `import appdirs`，但官方镜像无 appdirs 依赖
 - 修复: setup.cfg 补 `appdirs>=1.4.0`（官方 gold 的做法；eval.sh 的 `pip install -e .` 会读取新依赖并安装）
 - 教训: model_patch 改依赖声明时，官方流程会在应用 patch 后重装，依赖变更必须写进 setup.cfg/pyproject
- 2. **pylint-6528（递归 ignore）**：venv 同文件回归过，官方 P2P 3 失败
 - 根因: 提取 `_is_ignored_file` 时删除了循环内 `basename` 定义，并行 worker（multiprocessing）触发 `NameError: basename is not defined`
 - 修复: 补回 `basename = os.path.basename(something)`（与官方 gold 一致）
 - 结果: 修复后官方重跑 **resolved=True**（F2P 4/4 + P2P 全集通过）
 - 教训: venv 单进程回归测不出 multiprocessing 路径；官方 P2P 全集（含并行模式测试）能覆盖
- 3. **补丁污染测试文件的教训**：初版 6528 patch 含测试文件改动（新增测试+修改 `test_recursive_current_dir` 的 `chdir` 语义），官方判定失败——model_patch 只应包含 src 改动

局限

- **Rosetta 模拟风险**: x86_64 实例（4604/6386/7080）经 OrbStack + Rosetta 2 模拟 linux/amd64 镜像运行；绝大多数 Python 逻辑与原生 x86 等价，但少数系统调用、文件锁、信号、fork/multiprocessing 底层行为存在模拟层带来的潜在非确定性（本实验未发现受影响用例，如实声明）
- 未跑完整 500 实例，仅 pylint 子集——不代表 SWE-bench Verified 整体得分
- pylint-6528 经修复（补 basename 定义）后重跑 **resolved=True**，已计入统计