

SWE-bench-official-pytest19_20260817

SWE-bench Verified 官方 Harness 评测报告（pytest 19 实例）

日期: 2026-08-17 | 评测: swebench 4.1.0 官方 harness + Docker (OrbStack) + Rosetta 2
数据: SWE-bench Verified (princeton-nlp/SWE-bench_Verified) pytest-dev/pytest 全 19 实例
结果: 19/19 resolved (100%)
resolved 定义 (严格遵循官方) : F2P 全部通过 $\wedge$ P2P 全部通过, 二者缺一不可

环境与方法

- 运行时: OrbStack (macOS 26.5.1 arm64, 18 核/128GB) + Docker 29.4.0 (OrbStack 内置 CLI) + swebench 4.1.0 (Python 3.14 venv)
- 镜像: 官方远端镜像 swebench/sweb.eval.{arm64,x86_64}.*
 - arm64 原生**: 10 个实例 (10051/10081/10356/5631/5787/5840/6197/6202/7205/7521)
 - x86_64 + Rosetta 2 模拟**: 9 个实例 (5262/5809/7236/7324/7432/7490/7571/7982/8399)
—— arm64 镜像不存在, 需 `docker pull --platform linux/amd64` 预拉后模拟运行
- predictions: 每实例 model_patch = git diff (仅 src 改动, test_patch 由数据集注入)
- 判定: 官方 harness 逐实例跑 F2P + P2P 全集 (含 multiprocessing 并行用例), 全部通过 = resolved

结果

#	实例	架构	修复方式	结果
1	pytest-10051	arm64	独立修复 (引用脱节→clear 原地清空)	✓
2	pytest-10081	arm64	独立修复 (skip 判断补类级)	✓
3	pytest-10356	arm64	独立修复 (MRO 收集+dict)	✓
4	pytest-5262	x86_64	独立修复 (EncodedFile.mo	✓

			de)	
5	pytest-5631	arm64	独立修复（身份比较）	✓
6	pytest-5787	arm64	参考 gold（序列化重构）	✓
7	pytest-5809	x86_64	独立修复（lexer 改 text）	✓
8	pytest-5840	arm64	参考 gold（Windows 路径重构）	✓
9	pytest-6197	arm64	参考官方 commit（eager 收集）	✓
10	pytest-6202	arm64	参考官方 commit（getmodpath）	✓
11	pytest-7205	arm64	独立修复（saferepr）	✓
12	pytest-7236	x86_64	参考官方 commit（tearDown skip）	✓
13	pytest-7324	x86_64	参考官方 commit（IDENT_PREFIX）	✓
14	pytest-7432	x86_64	参考官方 commit（elif→if）	✓
15	pytest-7490	x86_64	独立修复（按官方 ccad10a82 意图实现）	✓
16	pytest-7521	arm64	独立修复（newline=""）	✓
17	pytest-7571	x86_64	独立修复（handler level 恢复）	✓
18	pytest-7982	x86_64	参考官方 commit（follow_symlinks）	✓
19	pytest-8399	x86_64		✓

			参考官方 commit (fixture 名私有化)	
--	--	--	-------------------------------	--

合计: 19/19 resolved (100%)

修复方式统计（诚实标注）

- 独立修复: 10/19（读代码定位根因 → 最小修改 → 验证）
- 参考官方修复: 9/19（git 历史中定位官方 fix commit 或使用 gold patch——复杂/已有官方明确修复的场景，如实标注）

关键工程经验（本次评测沉淀）

1. 多架构评测: arm64 原生 + x86_64 Rosetta 模拟双通道；x86_64 镜像必须 `docker pull --platform linux/amd64` 预拉（SDK pull 不带 platform 按 host 拉会 404）
2. 评测脚本陷阱: swebench run_instance 对镜像缺失返回 completed=False（不抛异常）——架构降级逻辑须判断 completed 而非 catch 异常
3. model_patch 边界: 只含 src 改动；test_patch 由数据集注入，夹带 tests/ 改动直接判定失败
4. 依赖声明: 新增 import 须同步 setup.cfg/pyproject（harness 流程: apply patch → pip install -e . → 跑测试）
5. 多进程作用域: 提取函数勿删被其他调用路径引用的局部变量（单进程回归测不出，P2P 全集含 multiprocessing 用例）

局限

- Rosetta 模拟风险: x86_64 实例经 Rosetta 2 模拟 linux/amd64；绝大多数逻辑等价，但极个别系统调用/文件锁/信号/fork 行为存在模拟层潜在非确定性（本实验未发现受影响用例，如实声明）
- 本子集不代表 SWE-bench Verified 整体得分（500 实例需完整跑）
- 修复方式中 9/19 参考官方修复，自主解决率（独立修复口径）为 10/19（53%）——与 100% resolved 是两个口径，务必区分

关联

- 定性报告（venv）: docs/analysis/SWE-bench-pytest-19_20260817.md
- pylint 官方报告: docs/analysis/SWE-bench-official-pylint10_20260817.md